人工智能基础

大作业

强化学习：迷宫求解

学　　号　　**2017011589**

姓　　名　　**吾尔开西**

专　　业　　**自动化**

日　　期　　**2019.10.12**

目录

任务描述 2

1、 必做任务一 2

2、 必做任务二 3

3、 必做任务三 3

4、 选做任务一 3

问题建模 4

1、迷宫 4

2、Q 表模型 4

3、监督学习模型 5

4、Q-learning 学习过程 5

5、加入时间因子 5

算法设计和代码 6

1、迷宫类 6

2、Q 表模型类 6

UI 设计和使用说明 6

1、已有迷宫界面 6

2、用户自定义 7

总结 7

任务描述

1、 必做任务一

使用强化学习算法，对于给定的迷宫，训练老鼠在迷宫中寻找蛋糕。

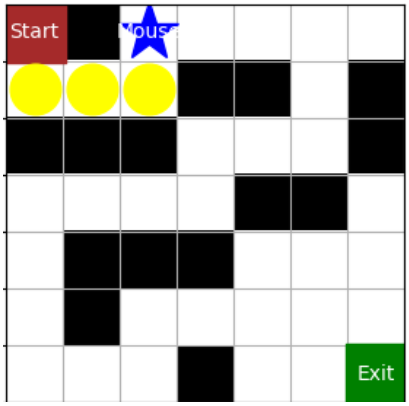

迷宫与图中类似，黑色格子为墙，不能走，老鼠试图走向墙时，会停在原地。白色格子为空地，可以走。黄色圆圈标志老鼠走过的格子，五角星为老鼠所在位置。起始位置为左上角，结束位置为右下角。

2、 必做任务二

自行生成不同迷宫（尺寸、地图），完成前述操作。

我对这个任务的理解是:程序中事先定义好了一些不同大小和样式的迷宫,供用户挑选,此外，用户也可以自己定义迷宫。

3、 必做任务三

若迷宫中存在老鼠夹子，且位置固定，完成前述操作。

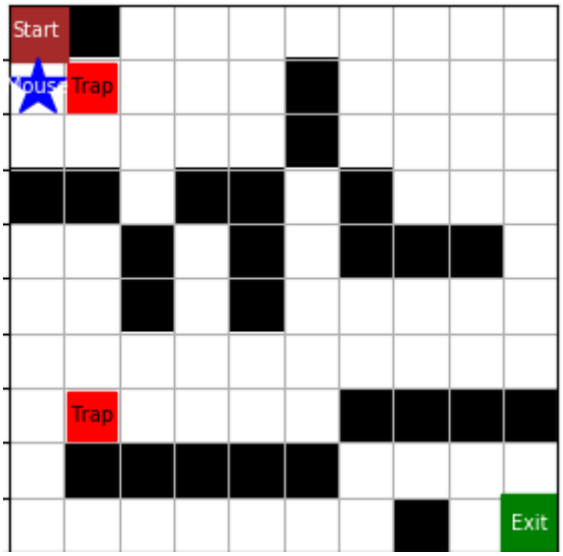

如图，红色方格代表陷阱，即老鼠夹子。与黑色方格的墙不同，老鼠可以走向陷阱，而一旦走入陷阱，游戏失败。

4、 选做任务一

考虑时变因素，如迷宫的某些格子会周期性产生火焰。

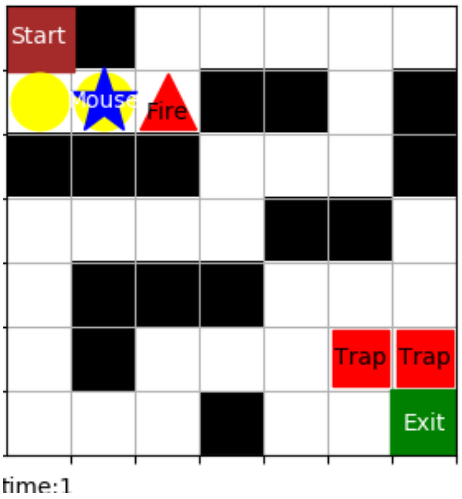

如图，红色三角为火焰，和陷阱相同，老鼠可以走向火焰，但一旦走入就会导致游戏失败。

设老鼠每走一步的时间为一个时间单位，火焰在一个周期时间（偶数个时间单位）内的后半段出现，前半段不出现。比如火焰周期为 4，老鼠走两步，火焰出现，再走两步，火焰消失。火焰周期可在用户自定义界面由用户定义。

问题建模

1、迷宫

迷宫用一个二维数组建模，数组中的每个数代表一个方格，数字值代表方格类型（如 0 表示墙, 2 表示陷阱, 3 表示火）。

迷宫是强化学习中的“环境”，老鼠在迷宫中每走一步（采取一个动作），迷宫会返回一个 reward，游戏状态（输或赢），以及老鼠下一个位置。

reward 基本都是负值，除了到达终点的动作。

动作	Reward
移动	-0.05
撞墙	-0.85
重复走过的格子	-0.3
死亡（陷阱或火焰）	-2
到达终点	1

之所以将移动的 reward 设为负值，是为了减少老鼠的路线长度，尽快到达终点。

为防止游戏无止境地进行下去，当 reward 积累到足够小时，游戏也会结束。

2、Q 表模型

使用 Q-learning 算法进行训练，就是要得到 Q 表：行动价值函数，对每一个状态的每个动作都有一个行动价值与其对应，做决策时选择当前状态下行动价值最高的动作。

动作：向上下左右四个方向前进。

状态：老鼠所在的格子（引入时间因素后还有考虑时间）。

下图是可视化的 Q 表, 从每个状态的四个动作中选出 Q 值最大的一个, 用箭头画出来, 颜色表示 Q 值大小，从红到绿 Q 值越来越大。

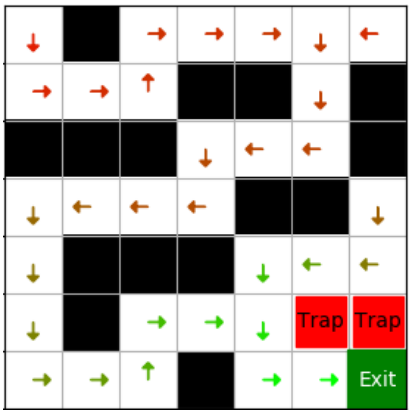

3、监督学习模型

除 Q 表模型外，我们也尝试了使用监督学习模型进行预测，将 1 中提到的代表迷宫的二维数组变成一维向量，输入到全连接网络中，网络输出1×4大小的向量，分别表示四个动作的 Q 值。

使用监督学习模型进行训练时，需要使用批量式价值近似方法。把训练数据存到一个库里，训练时从库里拿一批数据出来训练，即经验回放。注意库的大小有限，库满时删除旧数据，加入新数据。

4、Q-learning 学习过程

Q-learning 是一种离线策略学习的方法，行为策略采用ε-贪心策略，有利于进行探索，目标策略采用贪心策略，有利于充分利用学到的经验。

具体学习过程如下，在老鼠处于状态 state 时，首先基于当前 Q 表采用ε-贪心策略进行预测，选择一个动作A_t，采取该动作，从"环境"中得到反馈：下一状态S_{t+1}，回馈R_{t+1}，游戏状态（输赢）game_status。再采用贪心策略对下一状态S_{t+1}进行预测，得到$\mathrm{Q}(S_{t+1}, A_{t+1})$，使用时序差分方法对 Q 表进行更新：

$$\mathrm{Q}(S_t, A_t) \leftarrow \mathrm{Q}(S_t, A_t) + \alpha[R_{t+1} + \gamma \mathrm{Q}(S_{t+1}, A_{t+1}) - \mathrm{Q}(S_t, A_t)]$$

在每一局游戏的每一步移动都重复上面的步骤，直到游戏结束，一轮游戏叫做一个 epoch。训练会在足够多 epoch 后，或 Q 表足够完善时停止。

5、加入时间因子

选做任务中要求火焰周期性变化，因此我们需要在状态中加入时间维度，Q 表也会发生响应的变化。

迷宫问题符合马尔可夫过程的定义，即当前状态下的决策与之前的步骤无关。加入时间因子后也是如此，当前状态下，即考虑时间和老鼠的位置，进行的决策与过去的步骤无关。因此时间因子不是无限大的，但又因为"环境"的反馈与时间有关，所以需要考虑一个周期内的时间因子即可。比如火焰出现周期为 4，则时间变量的取值范围为 0，1，2，3，变化规律为：$0 \to 1 \to 2 \to 3 \to 0 \to 1 \to 2 \ldots$

在不加入时间因子时，状态由一个二元组表示(x,y)，即老鼠的坐标；加入时间因子后，状态由三元组表示(x,y,t)。Q 表也会扩大规模，比如火焰周期为 4 时，Q 表规模会变为原来的 4 倍。

下图是周期为 2 时 Q 表的可视化结果，每个坐标点有两个 Q 值，分别对应时间 0 和时间 1，时间 t 为 1 时火焰出现。

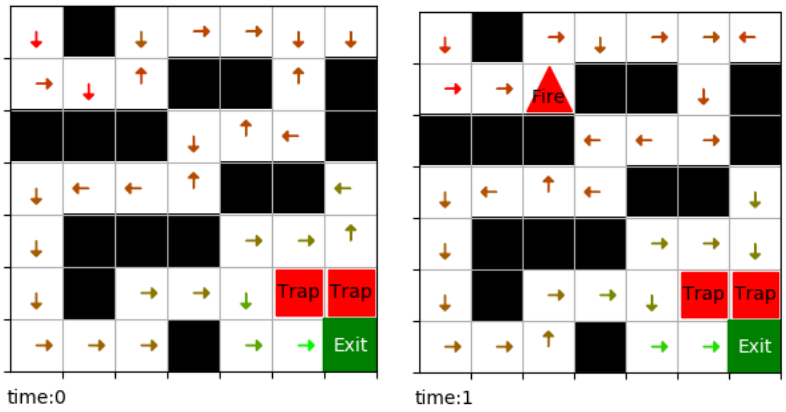

算法设计和代码

使用 Q 表模型时，核心算法主要有两个类：迷宫（环境）和 Q 表。我们将 Q 表的存储，预测，训练等放在一个类中实现。除此之外还有可视化，用户界面等代码中的类。

1、迷宫类

迷宫信息用一个二维数组表示，数组中的每个数代表一个方格，数字值代表方格类型（如 0 表示墙，2 表示陷阱，3 表示火）。

迷宫类接收决策动作，给出对应的反馈：下一状态S_{t+1}，回馈R_{t+1}，游戏状态（输赢）game_status。

2、Q 表模型类

Q 表类有 Q 值的存储，决策的进行，Q 表的学习等功能函数，进行预测和学习时会与迷宫（“环境”）进行交互，对其输入动作，得到反馈。

UI 设计和使用说明

UI 界面使用 pyqt 设计，虽然不方便使用拖放组件的方式设计，但纯编程的设计自由度更高，让我得以实现像用户自定义图形这样的复杂操作。UI 的最高层是一个 QMainWindow 组件，里面有一个标签页，包含三个标签，分别是：“已有迷宫”和“用户自定义”。

1、已有迷宫界面

已有迷宫界面允许用户从我们定义好的几个迷宫中选择一个，进行训练并查看完整的走迷宫过程。由于我们已经训练并存储好了这些迷宫的 Q 表，用户也可以不进行训练，直接查看走迷宫过程。

用户可以选择迷宫过程的播放速度，界面左面两个分别是可视化的 Q 表和走迷宫的路线。用户可以从 6 种迷宫中任选其一，6 种迷宫包括 2 种尺寸，3 种类型。3 种类型分别是：只有墙，有墙和陷阱，有火焰。火焰的周期默认为 2.

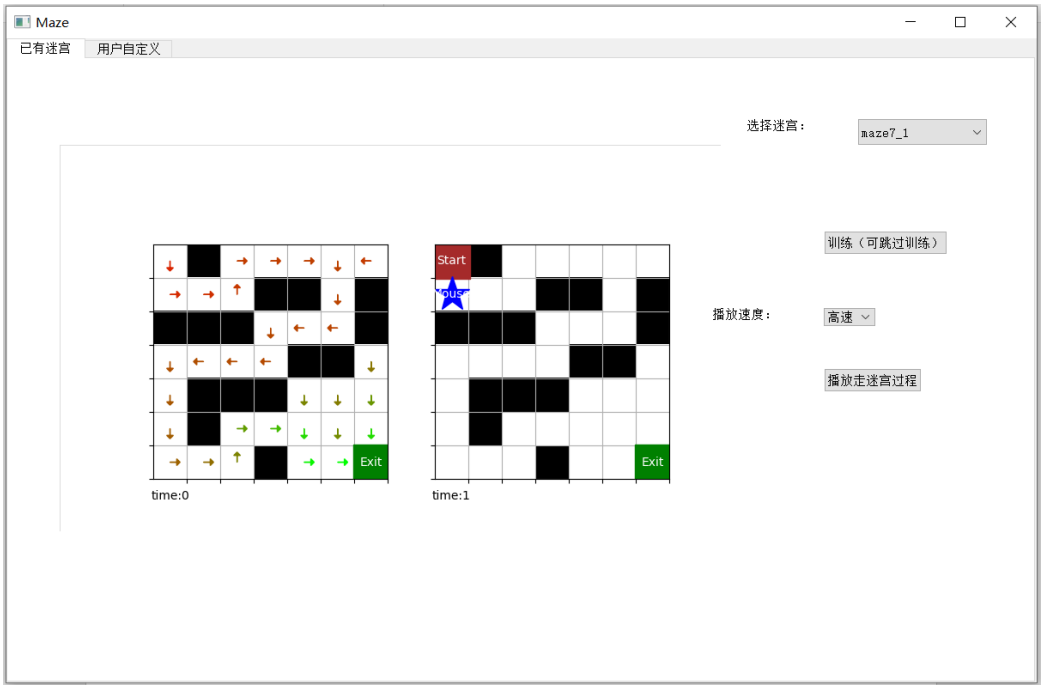

2、用户自定义

在用户自定义界面，用户可以输入任意大小的迷宫，自定义火焰周期，训练次数上限。之后进行训练，并以三种不同的速度查看完整的走迷宫结果。下面的 Q 表还没有经过训练，所以所有 4 个方向的 Q 值相等。

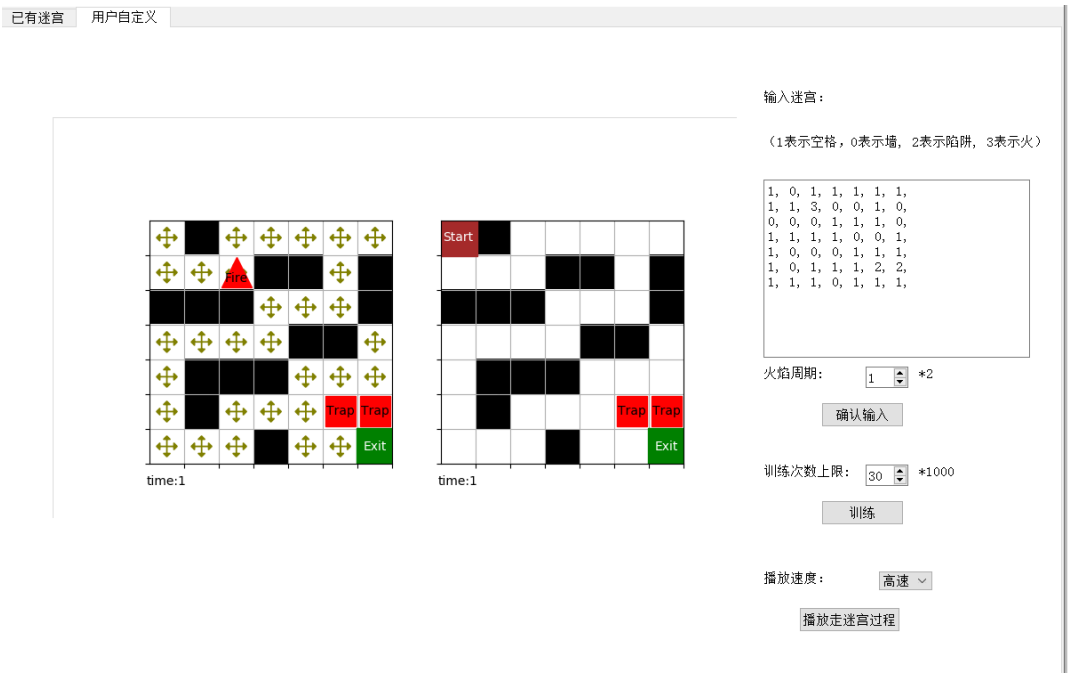

总结

本次大作业我尝试了 Q 表模型和监督学习模型。

一开始我直观地认为监督学习模型更好，但完成后才发现其训练速度慢，且算法复杂。

于是我又实现了 Q 表模型，训练速度很快，且算法直观。这让我体会到分析问题和文献调研的重要性，对不同的问题要用不同的解决方法，从难到易，杀鸡不用宰牛刀。

我完成了三个必做任务和选做任务，并设计了 UI 界面。此外，用户在 UI 界面有很大的自由度，可以自定义迷宫和迷宫参数。

虽然这次大作业花了我较长时间，尝试了两种方案，但体会到了独立完成一个完整项目的乐趣，收获了成就感，不仅提高了我的编程能力，加深了我对强化学习的理解，还提高了我解决问题的能力以及抗压能力，收获满满，也算是付出得到了回报。